UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
FACULTAD DE ESTUDIOS SUPERIORES ACATLÁN
Licenciatura en Matemáticas Aplicadas y Computación

INVESTIGACIÓN EN MATEMÁTICAS APLICADAS Y COMPUTACIÓN

Contenido sintético en Internet y degradación de modelos de lenguaje

Una aproximación al fenómeno de *Model Collapse*

Alumnos:
Carlos Emiliano Segura Loera
Valeria Hernandez Santos
Nehiel Ramirez Hernandez

Profesor:
Sergio Quiroz Almaraz

Fecha de entrega:
11 de noviembre de 2026

Naucalpan de Juárez, Estado de México

Índice

Resumen iv

1 Introducción 1
1.1 Contexto y motivación . . . 1
1.2 Planteamiento del problema . . . 1
1.3 Preguntas de investigación . . . 2
1.4 Objetivos de la investigación . . . 2
1.5 Hipótesis . . . 3
1.6 Justificación y aportación esperada . . . 3
1.7 Alcances y delimitaciones . . . 3

2 Marco teórico 4
2.1 Modelos generativos de lenguaje . . . 4
2.1.1 Generación de texto como proceso probabilístico . . . 4
2.1.2 Preentrenamiento y ajuste de modelos . . . 4
2.1.3 Estrategias de muestreo y decodificación . . . 4
2.2 Datos utilizados en el entrenamiento . . . 5
2.2.1 Datos de origen humano . . . 5
2.2.2 Datos sintéticos y semisintéticos . . . 5
2.2.3 Mezcla, reemplazo y acumulación de datos . . . 5
2.3 Entrenamiento recursivo . . . 5
2.3.1 Ciclos de entrenamiento y generación . . . 5
2.3.2 Transmisión de información entre generaciones . . . 6
2.4 El fenómeno de *model collapse* . . . 6
2.4.1 Definición y manifestaciones . . . 6
2.4.2 Cambios en la distribución del contenido . . . 6
2.4.3 Pérdida de patrones poco frecuentes . . . 7
2.4.4 Diferencias entre colapso, repetición y rendimiento . . . 7
2.5 Diversidad del contenido generado . . . 7
2.5.1 Diversidad léxica . . . 7
2.5.2 Diversidad semántica . . . 7
2.5.3 Diversidad sintáctica . . . 7
2.6 Repetición y concentración de patrones . . . 8
2.6.1 Repetición dentro de un texto . . . 8
2.6.2 Similitud entre textos generados . . . 8

2.7 Fundamentos de las métricas de evaluación 8
2.7.1 Medidas de diversidad léxica 8
2.7.2 Medidas de diversidad semántica 9
2.7.3 Medidas de repetición 9
2.7.4 Medidas de fidelidad distribucional y rendimiento 9

3 Estado del arte 10
3.1 Criterios de búsqueda y selección de literatura 10
3.2 Evidencia inicial y velocidad del deterioro 10
3.3 Estudios sobre pérdida de diversidad lingüística 10
3.4 Efectos de la proporción de datos sintéticos 11
3.5 Conservación de datos originales y acumulación 11
3.6 Influencia de las estrategias de generación 11
3.7 Estrategias de mitigación 12
3.8 Comparación crítica de los enfoques 12
3.9 Delimitación de la aportación del estudio 13

4 Metodología 13
4.1 Enfoque y diseño experimental 13
4.2 Variables y condiciones de comparación 14
4.3 Recursos e instrumentos computacionales 14
4.4 Modelo y tarea 14
4.5 Selección y preparación de los datos 14
4.6 Presupuesto y definición de una generación 15
4.7 Procedimiento de ajuste 16
4.8 Generación de continuaciones 16
4.9 Métricas de evaluación 16
4.10 Análisis de resultados 17
4.11 Piloto y viabilidad temporal 17
4.12 Reproducibilidad y consideraciones de uso 18

5 Resultados 18
5.1 Ejecución y verificación de los datos 18
5.2 Perplejidad sobre referencias originales 19
5.3 Diversidad léxica y repetición 20
5.4 Dispersión semántica 21
5.5 Interacción entre proporción sintética y generaciones 21

5.6 Variabilidad entre repeticiones 21
5.7 Ejemplos de continuaciones 22
5.8 Aspectos previstos que no se evaluaron 22

6 Discusión 23
6.1 Lectura de los resultados frente a la hipótesis 23
6.2 Relación con la literatura 23
6.3 Limitaciones 24

7 Conclusiones 24
7.1 Respuesta a la pregunta principal 24
7.2 Respuestas a las preguntas secundarias 25
7.3 Cumplimiento de los objetivos 25
7.4 Conclusión sobre la hipótesis 25
7.5 Aportaciones del estudio 26
7.6 Limitaciones y trabajo futuro 26

Referencias 27

A Configuración completa del experimento 29

B Tablas completas de resultados 29

RESUMEN

El crecimiento de la inteligencia artificial generativa ha incrementado la presencia de contenido sintético en Internet, lo que plantea interrogantes sobre las consecuencias de reutilizarlo en el entrenamiento de futuras generaciones de modelos de lenguaje. El fenómeno conocido como *model collapse* describe la degradación que puede producirse cuando los modelos aprenden de manera recurrente a partir de datos generados por otros modelos. En este trabajo se estudió experimentalmente este proceso con un GPT-2 pequeño en español, ajustado sobre fragmentos de Wikipedia durante cinco ciclos de generación y reentrenamiento, con tres proporciones de continuaciones sintéticas (0, 50 y 100 %) y tres repeticiones, para un total de 48 ajustes ejecutados en Google Colab con una GPU T4. Se evaluaron la perplejidad sobre texto humano reservado, la diversidad léxica, la repetición y la dispersión semántica. Con reemplazo total de los datos originales, la perplejidad aumentó cerca de un 29 % en cinco ciclos, la diversidad léxica disminuyó y la repetición aumentó de forma consistente en las tres repeticiones. Al conservar la mitad de los datos originales, la perplejidad aumentó menos del 5 % y se estabilizó, y con datos originales no se observó deterioro. La dispersión semántica no disminuyó en ninguna condición. Las métricas léxicas y semánticas se describieron mediante un análisis complementario, debido a una regla de longitud que dejó sin valores a la mayoría de las etapas. Los resultados son compatibles con una etapa temprana de *model collapse* bajo reemplazo total y sugieren que conservar datos originales reduce el efecto, dentro de las limitaciones de escala del experimento.

Palabras clave: contenido sintético, modelos de lenguaje, *model collapse*, datos sintéticos, diversidad lingüística.

1. Introducción

1.1. Contexto y motivación

La generación automática de texto plantea una cuestión relevante para el desarrollo de modelos de lenguaje: qué ocurre cuando sus propias respuestas se incorporan a los datos utilizados para entrenar modelos posteriores. Si este proceso se repite, el contenido producido por una generación pasa a formar parte de la información de la siguiente. En este escenario, interesa estudiar si se conserva la variedad del contenido original o si las respuestas se concentran progresivamente en determinados patrones.

El interés inicial de esta investigación surge de la llamada teoría del "Internet muerto", utilizada como punto de partida para reflexionar sobre la presencia de contenido automatizado en la Web. Sin embargo, el estudio no busca comprobar dicha teoría ni estimar qué proporción de Internet es producida por inteligencia artificial. La motivación se concreta en un problema experimental: analizar las consecuencias de reutilizar texto sintético durante sucesivos ciclos de entrenamiento.

1.2. Planteamiento del problema

El fenómeno conocido como *model collapse* describe un deterioro que puede aparecer cuando los modelos se entrenan recursivamente con datos generados por modelos anteriores. Shumailov et al. [1] estudian este proceso y señalan la pérdida de información correspondiente a regiones poco probables de la distribución original. Este antecedente motiva observar tanto la variedad del texto generado como su concentración en patrones frecuentes.

El efecto no debe suponerse idéntico en todas las condiciones. Kazdan et al. [2] muestran diferencias entre reemplazar los datos originales, acumularlos junto con datos sintéticos y entrenar con subconjuntos de tamaño fijo. Por ello, la presencia de datos sintéticos no es suficiente para anticipar el resultado: también importa el procedimiento mediante el cual se incorporan al entrenamiento.

El problema de esta investigación consiste en determinar cómo cambia la diversidad del contenido generado cuando se reutilizan datos sintéticos de manera recurrente. En particular, se busca examinar los cambios léxicos y semánticos, la repetición de patrones y su relación con la proporción de datos sintéticos y el número de generaciones. El análisis busca distinguir los cambios observados de una interpretación más amplia sobre la aparición de efectos asociados con el *model collapse*.

1.3. Preguntas de investigación

La pregunta principal que orienta el estudio es:

¿Cómo cambia la diversidad del contenido generado por modelos de lenguaje cuando se incorporan repetidamente datos sintéticos al proceso de entrenamiento?

De ella se desprenden cinco preguntas secundarias:

1. ¿Cómo cambia la diversidad léxica y semántica del contenido generado conforme aumenta el número de generaciones de entrenamiento con datos sintéticos?
2. ¿Cómo influye la proporción de datos sintéticos utilizados durante el entrenamiento en la diversidad del contenido generado?
3. ¿Cómo cambia la frecuencia de patrones, frases o estructuras repetitivas conforme se incorporan datos sintéticos de manera recurrente?
4. ¿Qué relación existe entre la proporción de datos sintéticos y el número de generaciones de entrenamiento en los cambios observados en la diversidad del contenido?
5. ¿Qué características del contenido generado permiten identificar la aparición de un proceso asociado con el *model collapse*?

1.4. Objetivos de la investigación

El objetivo general es analizar experimentalmente los cambios en la diversidad y repetición del contenido generado por un modelo de lenguaje de escala reducida ante la reutilización recurrente de datos sintéticos.

De este objetivo se desprenden los siguientes objetivos específicos:

1. Comparar la diversidad léxica y semántica del contenido generado a través de sucesivos ciclos de entrenamiento.
2. Examinar cómo varían estas dimensiones al modificar la proporción de datos sintéticos utilizada.
3. Evaluar los cambios en la repetición de patrones dentro de los textos y entre las respuestas generadas.
4. Analizar el efecto conjunto de la proporción sintética y del número de generaciones sobre las dimensiones estudiadas.
5. Examinar si los cambios observados son compatibles con efectos asociados con el *model collapse*, considerando las condiciones y limitaciones del experimento.

1.5. Hipótesis

El entrenamiento recurrente de modelos de lenguaje utilizando contenido generado por otros modelos produce una disminución progresiva en la diversidad del contenido generado y un incremento en la repetición de patrones lingüísticos. Se espera que estos efectos sean más pronunciados conforme aumenta la proporción de datos sintéticos empleada y el número de generaciones sucesivas de entrenamiento.

Esta hipótesis se contrastó dentro de las condiciones definidas para el experimento. No se presupone que el deterioro ocurra en todas las proporciones ni que afecte del mismo modo a todas las dimensiones evaluadas.

1.6. Justificación y aportación esperada

Desde las matemáticas aplicadas y la computación, el problema permite estudiar propiedades estadísticas del contenido generado y comparar su evolución bajo condiciones controladas. Su interés radica en relacionar la reutilización de datos con características observables del texto, sin requerir reproducir el entrenamiento de un modelo comercial de gran escala.

La aportación esperada consiste en desarrollar una aproximación experimental accesible y reproducible, con decisiones de entrenamiento y evaluación documentadas. El fenómeno ya cuenta con antecedentes; por ello, la contribución se precisa a partir del modelo, los datos y el protocolo seleccionados, así como del análisis de sus resultados: una comparación controlada en español, con tres proporciones sintéticas y tres repeticiones, ejecutable con recursos de cómputo limitados.

1.7. Alcances y delimitaciones

El trabajo se centra en la generación de texto mediante modelos pequeños o compactos y conjuntos de datos de tamaño controlado. No se contempla entrenar modelos de gran tamaño desde cero. Se utilizaron datos públicos, sin recurrir a información personal ni a interacción con usuarios.

Se trabajó en español con un GPT-2 pequeño, datos de Wikipedia y tres proporciones de objetivos sintéticos, durante cinco ciclos y tres repeticiones. La metodología detalla esta configuración y las métricas utilizadas. Un piloto permitió comprobar el funcionamiento a escala reducida antes de ejecutar el estudio principal completo. Los hallazgos se interpretan dentro de ese alcance, sin extrapolarlos directamente a todos los modelos de lenguaje ni al comportamiento de Internet en su conjunto.

2. Marco teórico

2.1. Modelos generativos de lenguaje

2.1.1. Generación de texto como proceso probabilístico

Un modelo de lenguaje asigna probabilidades a secuencias de unidades textuales o *tokens*. Estas unidades pueden corresponder a palabras, fragmentos de palabras u otros símbolos, según la representación utilizada. El modelado probabilístico busca aprender regularidades de las secuencias observadas para estimar la probabilidad de otras secuencias [3]. En un modelo autorregresivo, la probabilidad de un texto $x = (x_1, \ldots, x_T)$ se expresa mediante la regla de la cadena:

$$p_\theta(x) = \prod_{t=1}^{T} p_\theta(x_t \mid x_{<t}), \tag{1}$$

donde θ representa los parámetros aprendidos y $x_{<t}$ el contexto anterior al token t. Generar texto consiste en seleccionar sucesivamente tokens a partir de estas distribuciones condicionales.

La arquitectura Transformer introdujo un procesamiento de secuencias basado en mecanismos de atención [4]. Este antecedente permite comprender la arquitectura de numerosos modelos actuales, incluido el GPT-2 utilizado en este estudio, aunque no implica que todos los modelos generativos tengan la misma configuración.

2.1.2. Preentrenamiento y ajuste de modelos

El preentrenamiento permite aprender regularidades a partir de un corpus inicial. El ajuste posterior parte de parámetros previamente aprendidos y los modifica utilizando otros datos o un objetivo específico. Por ejemplo, el ajuste con instrucciones utiliza ejemplos de solicitudes y respuestas para modificar el comportamiento de un modelo preentrenado [6]. Reentrenar desde cero y ajustar un modelo existente son procedimientos distintos; en este trabajo cada ciclo ajusta un modelo ya preentrenado, sin entrenarlo desde cero.

2.1.3. Estrategias de muestreo y decodificación

La distribución aprendida no determina por sí sola el texto que se obtiene. La decodificación voraz elige el token más probable, mientras que el muestreo selecciona entre alternativas de manera probabilística. La temperatura modifica la concentración de las probabilidades; *top-k* restringe la selección a un número de candidatos, y *top-p* utiliza un conjunto cuya masa de probabilidad acumulada alcanza un umbral. Holtzman et al. [5] muestran que la elección de decodificación puede cambiar la diversidad y repetición sin modificar los

parámetros del modelo. Por ello, el análisis debe distinguir los efectos del entrenamiento de los producidos por la generación.

2.2. Datos utilizados en el entrenamiento

2.2.1. Datos de origen humano

En este trabajo se denomina dato de origen humano al texto producido por personas que se utilice como referencia inicial. Se trata de una definición operativa: el origen no garantiza por sí mismo calidad, representatividad ni ausencia de duplicados, por lo que la procedencia, las licencias y los criterios de selección del corpus se documentan en la metodología.

2.2.2. Datos sintéticos y semisintéticos

Los datos sintéticos son ejemplos producidos mediante un modelo generativo. Su utilización puede responder a finalidades diferentes. Self-Instruct genera instrucciones y ejemplos, filtra casos inválidos o similares y los utiliza para ajustar un modelo [6]. Los datos semisintéticos combinan material original con transformaciones generadas; Zhu et al. [7] estudian la edición de tokens sobre textos humanos. Por tanto, generar documentos completos y modificar parcialmente textos existentes no constituyen tratamientos equivalentes.

2.2.3. Mezcla, reemplazo y acumulación de datos

Pueden distinguirse tres políticas: mezclar datos originales y sintéticos en una proporción definida; reemplazar datos de una generación por los de la siguiente; y acumular los conjuntos disponibles. Además, conservar un corpus creciente y entrenar con todo él es distinto de extraer un subconjunto de tamaño fijo en cada ciclo. Estas diferencias son relevantes para interpretar el comportamiento del entrenamiento recursivo [2]. La proporción sintética debe especificar su unidad de cálculo, por ejemplo documentos o tokens, y no solo un porcentaje sin referencia. En este estudio se utiliza una mezcla con presupuesto fijo, medida en tokens de las continuaciones.

2.3. Entrenamiento recursivo

2.3.1. Ciclos de entrenamiento y generación

El entrenamiento recursivo introduce una dependencia entre generaciones: un modelo produce datos que se utilizan para entrenar o ajustar otro modelo. Como esquema conceptual, puede representarse mediante

$$D_g \longrightarrow M_g \longrightarrow S_g \longrightarrow D_{g+1}, \tag{2}$$

donde D_g es el conjunto usado en la generación g, M_g el modelo resultante y S_g sus datos sintéticos. El conjunto siguiente puede incorporar datos originales y sintéticos, según la política seleccionada. Este esquema describe la dependencia entre datos y modelos [1, 2]; su concreción en este estudio se presenta en la metodología.

2.3.2. Transmisión de información entre generaciones

Cada conjunto generado es una muestra finita del comportamiento del modelo, no una copia exacta de la distribución inicial. Un patrón poco probable puede no aparecer en esa muestra y perder representación en los datos posteriores. El ajuste puede añadir diferencias de aproximación respecto de los datos recibidos. Shumailov et al. [1] analizan cómo estos errores pueden acumularse. También importa si cada ciclo parte de una copia del mismo modelo base o de los parámetros del ciclo anterior; en este trabajo se adoptó la primera opción, de modo que la información pasa de una generación a otra solo a través de los datos.

2.4. El fenómeno de *model collapse*

2.4.1. Definición y manifestaciones

El *model collapse* se refiere a una degradación asociada con la reutilización de datos generados por modelos anteriores. Puede manifestarse como pérdida de información de la distribución original y reducción de la variabilidad del contenido [1]. Su estudio requiere describir el procedimiento y los indicadores observados, sin asumir que todo uso de datos sintéticos tendrá el mismo efecto.

2.4.2. Cambios en la distribución del contenido

La velocidad del deterioro también requiere atención. Suresh et al. [14] caracterizan tasas de colapso en distribuciones discretas y gaussianas bajo estimación de máxima verosimilitud o aproximaciones a ella. En esos escenarios simplificados, el olvido puede requerir muchas iteraciones. Este resultado no fija una tasa para los modelos de lenguaje, pero distingue la posibilidad de colapso de su rapidez observable en un experimento de duración limitada.

La distribución de las respuestas puede cambiar en el vocabulario, los patrones o los temas representados. Una mayor concentración implica que ciertas alternativas reúnen una parte mayor de las observaciones. Las frecuencias de palabras o de n-gramas permiten estudiar aspectos de ese cambio, pero no describen por completo la distribución del lenguaje ni su significado [7].

2.4.3. Pérdida de patrones poco frecuentes

Las colas de una distribución corresponden, en este contexto, a eventos con baja probabilidad. Su pérdida puede preceder a una concentración más severa del modelo [1]. Para estudiar patrones textuales poco frecuentes es necesario definirlos respecto de un corpus de referencia. Una reducción de vocabulario, por sí sola, no demuestra pérdida de información semántica ni permite identificar qué casos se omitieron.

2.4.4. Diferencias entre colapso, repetición y rendimiento

La repetición es una propiedad observable del texto y puede aparecer por la decodificación, sin entrenamiento recursivo [5]. El rendimiento, por su parte, depende de una tarea o evaluación definida. Drayson et al. [8] consideran conjuntamente rendimiento, características de generación y semejanza con referencias humanas. Estas dimensiones pueden ofrecer información complementaria; en este estudio ninguna se toma como prueba aislada y suficiente de colapso.

2.5. Diversidad del contenido generado

2.5.1. Diversidad léxica

La diversidad léxica describe la variedad de vocabulario y combinaciones de palabras. Dos conjuntos pueden diferir en términos distintos utilizados o en la frecuencia de sus combinaciones. Su comparación exige considerar el tamaño de muestra y las longitudes, pues afectan las medidas de variedad [9].

2.5.2. Diversidad semántica

La diversidad semántica se refiere a la variedad de significados expresados. Cambiar palabras no implica necesariamente cambiar el contenido. Las representaciones vectoriales de oraciones permiten aproximar relaciones de similitud semántica; Sentence-BERT utiliza representaciones comparables mediante similitud coseno [10]. Esa aproximación depende del modelo de representación, el idioma y la tarea, por lo que no debe tratarse como una medición directa y completa del significado.

2.5.3. Diversidad sintáctica

La diversidad sintáctica corresponde a la variedad de estructuras con que se organizan las oraciones. Guo et al. [9] distinguen las dimensiones léxica, sintáctica y semántica, mostrando

que no evolucionan necesariamente con la misma intensidad. Se incluye esta dimensión como fundamento conceptual; por factibilidad, no se incorporó a la evaluación de este estudio.

2.6. Repetición y concentración de patrones

2.6.1. Repetición dentro de un texto

Se entiende por repetición interna la reiteración de palabras, secuencias o fragmentos en una misma respuesta. Un n-grama es una secuencia de n unidades consecutivas; sus frecuencias permiten describir reiteraciones a distintas escalas. Conviene distinguir las repeticiones necesarias por el tema de aquellas que dominan la respuesta o forman bucles, un comportamiento relacionado también con la decodificación [5].

2.6.2. Similitud entre textos generados

La similitud entre respuestas describe hasta qué punto distintos textos repiten expresiones o contenidos. Un modelo puede generar respuestas internamente variadas y, sin embargo, producir casi la misma respuesta ante diferentes entradas. Texygen introduce Self-BLEU para comparar un texto generado con otros del mismo conjunto [12]. La similitud debe interpretarse junto con las entradas y la tarea: una respuesta factual admite menos variación que una tarea creativa.

2.7. Fundamentos de las métricas de evaluación

2.7.1. Medidas de diversidad léxica

La razón de tipos a tokens, TTR, divide el número de palabras distintas entre el total de palabras. Distinct-n, utilizado en generación de diálogo [11], relaciona las secuencias distintas de longitud n con el total observado. Para un texto x con N unidades y $N \geq n$, se puede expresar como

$$\text{Distinct-}n(x) = \frac{|\,\text{Unicos}_n(x)|}{N - n + 1}, \tag{3}$$

donde el numerador cuenta los n-gramas distintos. Debe precisarse si la medida se calcula por texto o sobre el conjunto concatenado. Guo et al. [9] controlan la longitud al emplear estas medidas; comparar tamaños diferentes puede confundir variedad y extensión.

2.7.2. Medidas de diversidad semántica

Para vectores de oración no nulos u y v, la similitud coseno es

$$\mathrm{sim}_{\cos}(u, v) = \frac{u \cdot v}{\|u\|\|v\|}. \tag{4}$$

El promedio de $1 - \mathrm{sim}_{\cos}$ entre pares ofrece una descripción de su separación en el espacio de representación. Su uso para diversidad requiere fijar el modelo de representaciones y el muestreo de pares, además de comprobar su adecuación al idioma [10, 9].

2.7.3. Medidas de repetición

La fracción de n-gramas repetidos describe reiteración superficial dentro de los textos. Self-BLEU toma cada texto como candidato y los demás como referencias, de modo que un valor alto indica mayor semejanza entre las salidas [12]. Es necesario especificar longitud del n-grama, tokenización y tamaño del conjunto de referencia. Estas medidas no identifican por sí solas equivalencia de significado.

2.7.4. Medidas de fidelidad distribucional y rendimiento

La perplejidad resume la probabilidad que un modelo asigna a una secuencia; para el modelo autorregresivo anterior, se expresa como

$$\mathrm{PPL}_\theta(x) = \exp\left(-\frac{1}{T}\sum_{t=1}^{T} \log p_\theta(x_t \mid x_{<t})\right). \tag{5}$$

Su comparación requiere condiciones equivalentes de tokenización y datos de evaluación. Una perplejidad baja no equivale necesariamente a mayor diversidad o calidad del texto [9].

MAUVE compara distribuciones de texto generado y humano mediante fronteras de divergencia [13]. Ofrece información complementaria a la variedad de palabras, pero no constituye una prueba automática de corrección factual ni de colapso. La selección final de métricas se presenta en la metodología; su presentación aquí establece los conceptos para justificar esa selección y sus límites.

3. Estado del arte

3.1. Criterios de búsqueda y selección de literatura

La revisión se orientó a trabajos sobre entrenamiento recursivo con datos sintéticos, diversidad lingüística y condiciones de mitigación. Se consultaron fuentes primarias en Nature, ACL Anthology, PMLR y arXiv, además de búsquedas por título y DOI en Scite. Se priorizaron antecedentes que permiten comparar políticas de datos, generación de texto o evaluación. Se distinguieron las publicaciones de sus preprints para evitar contar versiones de un mismo trabajo como evidencia independiente.

Se trata de una revisión dirigida al diseño del estudio, no de una revisión sistemática ni exhaustiva. El análisis combina resultados teóricos y experimentos, precisando sus respectivos alcances. Los trabajos seleccionados no utilizan necesariamente la misma definición operacional de colapso ni los mismos indicadores; por ello, sus resultados requieren compararse junto con el procedimiento que los produjo.

3.2. Evidencia inicial y velocidad del deterioro

Shumailov et al. [1] relacionan el entrenamiento recursivo con la pérdida de información de la distribución original. Su evaluación de lenguaje utiliza el ajuste de OPT-125m sobre WikiText-2 y generación mediante búsqueda en haz. El trabajo constituye un antecedente para observar cambios entre generaciones con modelos compactos, pero sus condiciones no equivalen a cualquier uso posible de datos sintéticos.

Suresh et al. [14] complementan esta perspectiva al estudiar la velocidad de pérdida bajo familias de distribuciones simplificadas y estimación de máxima verosimilitud o aproximaciones cercanas. Sus resultados muestran que el tamaño de muestra influye en la escala temporal del deterioro. La diferencia es relevante: demostrar una tendencia asintótica no determina que un experimento corto con un modelo de lenguaje muestre un colapso avanzado. Para el presente estudio, esto orienta a describir la magnitud de los cambios sin exigir de antemano un desenlace de colapso completo.

3.3. Estudios sobre pérdida de diversidad lingüística

Guo et al. [9] desplazan la atención desde el rendimiento hacia la diversidad léxica, sintáctica y semántica en tareas de generación en inglés. Mediante ajuste recursivo, encuentran reducciones especialmente claras en las dimensiones léxica y sintáctica, mientras que la dimensión semántica resulta relativamente más estable. Su evaluación incorpora medidas de vocabulario, coincidencia de secuencias y representaciones de oraciones, con controles de

longitud para las métricas sensibles a ella.

Este antecedente se relaciona directamente con la pregunta de investigación: el estudio de diversidad mediante modelos reducidos ya cuenta con evidencia previa. En consecuencia, la aportación se precisa en las condiciones comparadas y en la documentación del procedimiento. También es necesario justificar las herramientas lingüísticas al utilizar un idioma diferente, sin asumir que los resultados se trasladan automáticamente.

3.4. Efectos de la proporción de datos sintéticos

Zhu et al. [7] estudian distintas proporciones sintéticas y reportan una relación negativa con el rendimiento en sus configuraciones. Su análisis identifica cambios distribucionales y concentración de características de n-gramas. Además, proponen producir datos semisintéticos mediante edición de tokens de textos humanos y evalúan su uso en diferentes modalidades de entrenamiento.

Este trabajo aporta una razón para comparar proporciones, pero no establece un porcentaje universal de deterioro. El origen, la construcción y la selección del contenido intervienen junto con la cantidad utilizada. Para el diseño propio, modificar una proporción exige explicitar qué se conserva constante y qué se sustituye; de otro modo, el efecto podría confundirse con diferencias de volumen o composición del corpus.

3.5. Conservación de datos originales y acumulación

Gerstgrasser et al. [15] contrastan el reemplazo de datos con la conservación de los originales y la acumulación de generaciones sintéticas. En las condiciones evaluadas, la acumulación evita el deterioro observado al reemplazar los datos. Su preprint introduce así una distinción entre la presencia de contenido sintético y la política de conservación.

Kazdan et al. [2] comparan tres procedimientos: reemplazo, acumulación con uso de todos los datos y acumulación con subconjuntos de tamaño fijo. Reportan colapso con reemplazo, estabilidad de la pérdida de prueba al usar toda la acumulación y deterioro gradual con subconjuntos limitados. La lectura conjunta indica que conservar un corpus y utilizarlo íntegramente son decisiones distintas. Además, estabilidad de pérdida de prueba no demuestra por sí sola conservación de toda la diversidad.

3.6. Influencia de las estrategias de generación

Drayson et al. [8] analizan la decodificación en experimentos con GPT-2 y SmolLM2, considerando rendimiento, diversidad y semejanza con referencias humanas. Sus comparaciones muestran que cambiar la estrategia de generación modifica la trayectoria del deterioro. El

procedimiento que produce los datos sintéticos debe, por tanto, formar parte de la descripción experimental, en lugar de tratarse como un detalle secundario.

Esta perspectiva también limita la interpretación de una puntuación de diversidad aislada: una salida puede contener muchas secuencias diferentes y aun así deteriorarse en otros aspectos. Para la investigación se propone documentar entradas, longitudes y muestreo, y acompañar las medidas de diversidad con una evaluación complementaria cuya viabilidad se determine al cerrar el diseño.

3.7. Estrategias de mitigación

Los antecedentes revisados intervienen en distintos puntos del proceso. Gerstgrasser et al. [15] actúan sobre la conservación del corpus. Zhu et al. [7] modifican la construcción del dato sintético al mantener parte del texto humano. Drayson et al. [8] proponen remuestrear los datos utilizando estimaciones de un detector para dar mayor presencia a contenido probablemente humano.

Estas intervenciones no constituyen una misma solución. Cada una introduce supuestos y recursos propios: acceso al corpus original, posibilidad de editarlo o capacidad de detectar el origen de las muestras. Su utilidad para el proyecto consiste en orientar controles y explicar diferencias entre condiciones. La revisión no implica que todas deban implementarse ni que sus mejoras estén garantizadas fuera de los escenarios estudiados.

3.8. Comparación crítica de los enfoques

La comparación permite identificar tres diferencias que deben conservarse en el análisis. Primero, los resultados teóricos de distribuciones simplificadas no fijan directamente una tasa para modelos de lenguaje. Segundo, los estudios de acumulación pueden cambiar simultáneamente el origen y el volumen de los datos. Tercero, las medidas de diversidad, pérdida de prueba y calidad de generación evalúan dimensiones relacionadas, pero distintas [14, 2, 9, 8].

Por ello, diferencias entre hallazgos no deben interpretarse inmediatamente como contradicciones. Antes se requiere comparar modelo, tarea, corpus, inicialización de cada ciclo, política de conservación, presupuesto de entrenamiento y decodificación. También es necesario precisar si las repeticiones corresponden a cadenas de entrenamiento independientes o solamente a varias respuestas de un mismo modelo.

3.9. Delimitación de la aportación del estudio

La literatura ya ha documentado tanto deterioro como condiciones que lo modifican. La aportación de este trabajo se sitúa en una comparación controlada y accesible que relaciona proporción sintética y generaciones con diversidad y repetición. Su valor depende de definir las condiciones, documentarlas y analizar la incertidumbre de las observaciones, sin presentar como nuevo el fenómeno.

Esta revisión orienta el diseño comparativo en español que se desarrolla a continuación. La selección de recursos y controles se apoya también en un piloto de viabilidad; ninguno de estos elementos se utilizó para anticipar el sentido de los resultados de la comparación principal.

4. Metodología

4.1. Enfoque y diseño experimental

Se realizó un experimento comparativo en español con dos factores: proporción sintética y número de generaciones. La configuración principal se preparó después de un piloto de viabilidad y se ejecutó completa entre el 9 y el 10 de noviembre de 2026. El protocolo y los criterios de evaluación se fijaron antes de observar las comparaciones de prueba, sin exigir que se produjera un deterioro o un colapso avanzado.

La unidad básica del experimento es un ejemplo formado por un *contexto*, los primeros 64 tokens de un fragmento de Wikipedia, y su *continuación objetivo*, los 128 tokens que lo siguen. El modelo se ajusta para producir la continuación a partir del contexto. En términos generales, cada repetición del experimento sigue estos pasos:

1. Se ajusta el modelo preentrenado con las continuaciones originales y se obtiene la generación inicial, M_0.

2. El modelo de la generación anterior escribe nuevas continuaciones para los mismos contextos de entrenamiento.

3. Se arma el siguiente conjunto de entrenamiento: según la condición, se conservan las continuaciones originales, se reemplaza la mitad o se reemplazan todas por las generadas.

4. Se ajusta de nuevo el modelo preentrenado con ese conjunto, lo que da lugar a la siguiente generación.

5. La nueva generación se evalúa con contextos reservados que nunca se usan para entrenar.

Los pasos 2 a 5 forman un ciclo y se repiten cinco veces. Los apartados siguientes detallan cada elemento.

4.2. Variables y condiciones de comparación

La proporción sintética, α, se definió respecto del número de tokens objetivo utilizados para ajustar el modelo. Se utilizaron tres niveles: $\alpha = 0$, 0.5 y 1. El nivel cero fue la condición de referencia con datos originales; el nivel intermedio conservó la mitad de los tokens objetivo originales; el nivel uno los reemplazó por contenido sintético. Se realizaron cinco ciclos después de una generación inicial y tres cadenas independientes por condición; el diseño se completó sin omitir etapas.

Las variables de respuesta fueron diversidad léxica, dispersión semántica, repetición y perplejidad en datos reservados. Se mantuvieron constantes modelo base, tokenizador, número de ejemplos, longitudes, pasos de ajuste y configuración de generación. La comparación no incluyó acumulación de un corpus creciente; utilizó un presupuesto fijo por ciclo.

4.3. Recursos e instrumentos computacionales

El piloto y la ejecución principal se realizaron en Google Colab con una Tesla T4, registrando versiones de Python, PyTorch, Transformers, Datasets, Safetensors, CUDA y el acelerador. Esta disponibilidad no garantiza el mismo servicio en ejecuciones posteriores. El notebook principal guardó sus avances en una carpeta persistente de Google Drive; al reanudar, se comprobó que no cambiaran la configuración, el código ni el entorno esencial.

4.4. Modelo y tarea

Se utilizó `datificate/gpt2-small-spanish`, un GPT-2 pequeño adaptado al español a partir de un checkpoint inglés mediante datos de Wikipedia en español, según su ficha [16]. La tarea fue continuar fragmentos de texto en español, sin convertir el problema en seguimiento de instrucciones. El modelo tiene 124 439 808 parámetros, cantidad verificada al cargarlo, y permite un ajuste completo de escala acotada. Su selección no implica reproducir exactamente los experimentos de la literatura ni reclamar novedad por el idioma. Se conservaron la revisión y las condiciones de uso del recurso.

4.5. Selección y preparación de los datos

Se utilizó `wikimedia/wikipedia`, configuración `20231101.es`, con registros de artículos en español [17]. La ficha ofrece una sola partición oficial; entrenamiento, validación y prueba fueron particiones propias por artículo. Se aplicó SHA-256 a la semilla de partición y

al ID del artículo, tomando los primeros ocho bytes módulo 100: valores menores que 80 se asignaron a entrenamiento, de 80 a 89 a validación y el resto a prueba. Se conservó la semilla 20261109 del piloto para no trasladar sus artículos de ajuste o validación a la referencia final de prueba.

Se leyeron en orden los primeros 2000 artículos del corpus. El texto se normalizó a Unicode NFC, conservando tildes y ñ, y se tokenizó sin añadir tokens especiales. De cada artículo suficientemente largo se seleccionó, con semilla fija, una ventana entre bloques no solapados de 64 tokens de contexto y 128 de objetivo. Después se seleccionaron 512 artículos para entrenamiento, 128 para validación y 128 para prueba. Las tres muestras fueron disjuntas y se comprobaron IDs, hashes de contenido y ventanas exactas; una muestra insuficiente o duplicada detenía la preparación.

La partición de validación se utilizó para fijar la longitud común de las métricas antes de evaluar los modelos en prueba. Los 128 contextos de prueba y sus continuaciones originales fueron iguales para todas las condiciones y repeticiones. El prefijo acotado no es representativo de toda Wikipedia ni de Internet. Además, el corpus no certifica autoría humana individual y el modelo ya fue adaptado a Wikipedia: la separación propia no demuestra ausencia de solapamiento con su entrenamiento previo. Estas limitaciones se conservaron al interpretar la referencia y la perplejidad.

4.6. Presupuesto y definición de una generación

La generación inicial, M_0, se obtuvo ajustando el modelo base sobre los 512 ejemplos originales. Para cada repetición, ese mismo punto inicial sirvió para las tres proporciones. Cada generación posterior comprendió: producción de continuaciones con el modelo anterior, construcción de la mezcla, ajuste y evaluación del modelo resultante.

Cada ajuste partió de una copia del mismo checkpoint preentrenado, con optimizador nuevo. Así, la transmisión entre generaciones ocurrió mediante los datos y no por la acumulación de actualizaciones en los parámetros. Los contextos humanos permanecieron fijos en todos los niveles de mezcla; la proporción sintética se aplicó exclusivamente a las continuaciones. Por tanto, $\alpha = 1$ no significó ausencia total de contexto humano.

Cada conjunto contuvo $512 \times 128 = 65\,536$ tokens objetivo. La mitad sintética correspondió a 256 continuaciones originales y 256 generadas, seleccionadas mediante una permutación documentada. Los 256 IDs sintéticos fueron fijos a través de los ciclos de una misma repetición. Se generaron 512 continuaciones en cada ciclo no humano antes de aplicar la mezcla. La comparación completa requirió 45 ajustes posteriores y tres ajustes iniciales, además del muestreo y la evaluación, es decir, 48 ajustes en total.

4.7. Procedimiento de ajuste

Se mantuvo una época por ajuste, tasa de aprendizaje 2×10^{-5}, AdamW con $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$ y decaimiento de pesos 0.01 en todos los parámetros. Se utilizó float32, recorte de norma de gradiente a 1, sin programación de la tasa de aprendizaje ni precisión mixta. El lote efectivo fue de ocho ejemplos, procesados en grupos de dos con acumulación de gradientes. La función de pérdida se calculó únicamente sobre los tokens objetivo; los tokens del contexto y del relleno se enmascararon. Con 512 ejemplos y lote efectivo ocho se obtuvieron 64 actualizaciones por ajuste.

Se actualizaron todos los parámetros. Al iniciar cada ajuste se verificó que los pesos fueran exactamente los preentrenados y que el optimizador empezara vacío. No fue necesario modificar el protocolo por falta de recursos, y los datos de prueba no se usaron para elegir configuraciones ni modelos.

4.8. Generación de continuaciones

Se utilizó temperatura 1.0 y *top-p* 0.95, sin *top-k*, penalización de repetición ni búsqueda en haz. Se generaron exactamente 128 tokens por continuación, excluyendo los IDs especiales, incluido el de finalización. Esta restricción, verificada en el piloto, modifica la distribución de decodificación y se mantuvo constante entre condiciones. Los objetivos originales se tomaron sin agregar tokens especiales. No se filtraron salidas por idioma, calidad o valor de las métricas; los textos y sus incidencias se conservaron.

La producción de datos del siguiente ciclo utilizó contextos de entrenamiento; la evaluación utilizó los contextos reservados. Se separaron las semillas de inicialización del ajuste, muestreo del corpus y generación. Cada solicitud tuvo una semilla identificable, evitando compartir y repetir inadvertidamente un mismo flujo aleatorio entre textos. Las semillas del ajuste difirieron entre repeticiones y ciclos, y se emparejaron entre proporciones del mismo ciclo. Las de evaluación fueron iguales por contexto dentro de una repetición a través de sus etapas.

4.9. Métricas de evaluación

Se calcularon Distinct-2 y Distinct-3 como n-gramas únicos entre n-gramas totales del corpus, sin cruzar fronteras de texto. La repetición de 4-gramas fue el promedio por salida de uno menos la proporción de 4-gramas únicos. Se utilizaron las primeras W palabras en minúsculas, con W igual al mínimo entre 32 y la longitud de la continuación original más corta de validación. Se conservaron tildes y ñ, sin stemming ni eliminación de palabras vacías. El protocolo establecía que, si alguna salida no alcanzaba W, se registraría y las métricas léxicas

y semánticas de esa etapa quedarían ausentes, sin excluir respuestas silenciosamente.

La diversidad semántica se aproximó mediante la media de la distancia coseno entre pares de representaciones de las continuaciones, excluyendo el contexto de entrada. Se utilizó `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2`, codificador multilingüe que permite trabajar con español [18], con mean pooling enmascarado y normalización L2. Su límite fue 128 wordpieces, registrando truncamientos y usando la misma revisión para todas las etapas. No se añadió una métrica sintáctica en este diseño de alcance reducido.

La perplejidad se calculó sobre los mismos tokens originales reservados, con igual tokenización y enmascaramiento. Se acompañaron los indicadores con los primeros ejemplos por orden guardado, para examinar coherencia sin reemplazar las mediciones por una selección de casos llamativos. La pérdida de patrones raros no se infiere a partir de Distinct-n: su evaluación específica requeriría un procedimiento adicional definido antes del análisis y quedó fuera del alcance de esta ejecución.

4.10. Análisis de resultados

La unidad de réplica fue la cadena de entrenamiento y no cada respuesta. Se presentaron trayectorias por generación para cada proporción y repetición. Se resumieron los cambios respecto de M_0 y las diferencias frente a la condición sin datos sintéticos en la misma generación. Los contrastes de proporciones aprovecharon el punto inicial compartido por repetición, manteniendo identificada esa dependencia.

Las métricas de prueba se guardaron por etapa, pero el notebook presentó su resumen conjunto al completar el diseño; no se utilizaron para cambiar hiperparámetros o decidir detención temprana. Con tres repeticiones se dio prioridad a tamaños de cambio, medias y rangos entre cadenas. Las comparaciones fueron exploratorias; no se presentaron las 128 respuestas como réplicas de entrenamiento independientes ni se interpretó ausencia de significación como ausencia demostrada de efecto. El número de repeticiones se mantuvo en tres.

4.11. Piloto y viabilidad temporal

Se realizó un piloto separado con 64 ejemplos, 32 contextos de validación, dos proporciones extremas, dos ciclos y una repetición. Completó cinco ajustes y controles de enmascaramiento, generación y métricas; sus resultados no se integraron como réplicas de la comparación principal. Los tiempos del piloto orientaron el presupuesto del estudio principal. En este último se comprobó primero una etapa y su reanudación desde Drive antes de continuar

con el resto del diseño.

La estimación consideró todos los ciclos, condiciones y repeticiones, además de guardado y posibles interrupciones. Se había previsto que, si el diseño no cabía en el plazo, se reduciría primero el número de ejemplos o generaciones, por viabilidad y no según el efecto observado en el piloto. Esta reducción no fue necesaria: los 48 ajustes se completaron con una reanudación, con unas 2.8 horas de cómputo registrado en una T4.

4.12. Reproducibilidad y consideraciones de uso

Se registraron la configuración, las versiones del software, las revisiones del modelo y del corpus, las particiones, las semillas, los registros de entrenamiento, las continuaciones generadas y las métricas de cada etapa. Cada etapa completa se verificó mediante sumas de comprobación de sus archivos, de modo que una interrupción no pudiera mezclarse con resultados parciales: un ajuste interrumpido se repetía desde el modelo base con la misma semilla. No se utilizaron datos personales, y los recursos empleados son públicos. Este informe distingue lo planeado de lo efectivamente ejecutado. El diseño experimental se completó sin cambios; la única desviación del análisis previsto fue el análisis complementario de las métricas léxicas y semánticas, descrito en los resultados.

5. Resultados

5.1. Ejecución y verificación de los datos

El estudio principal se completó entre el 9 y el 10 de noviembre de 2026 en Google Colab con una Tesla T4. Se confirmaron las 48 etapas previstas: tres generaciones iniciales y 45 ajustes posteriores, distribuidos en tres repeticiones, tres proporciones y cinco ciclos. Cada ajuste realizó 64 actualizaciones sobre 65 536 tokens objetivo. La ejecución requirió una reanudación desde Drive y registró unas 2.8 horas de cómputo. Las etapas se verificaron mediante sus hashes y el marcador final del estudio; no se registraron truncamientos del codificador semántico. La longitud común de las métricas léxicas, fijada con validación, fue $W = 30$ palabras.

La perplejidad sobre las continuaciones originales de prueba se obtuvo en las 48 etapas, pues no depende de los textos generados. En cambio, la regla establecida en la metodología dejó sin métricas léxicas ni semánticas a 39 de las 48 etapas. De las 6 144 continuaciones evaluadas (48 etapas por 128 contextos), 75 no alcanzaron 30 palabras, y bastaba una de ellas para invalidar la etapa completa. Estas continuaciones cortas aparecieron en todas las condiciones: dos en las generaciones iniciales, 19 con $\alpha = 0$, 16 con $\alpha = 0.5$ y 38 con $\alpha = 1$.

Con frecuencia contienen secuencias largas de saltos de línea o de símbolos repetidos, por lo que su aumento con $\alpha = 1$ es, en sí mismo, una señal de deterioro.

Para no dejar sin descripción las dimensiones léxica y semántica, se realizó un análisis complementario *post hoc*. Se seleccionaron los 90 contextos de prueba cuyas continuaciones alcanzan W palabras en las 48 etapas, de modo que todas las etapas se comparan con los mismos contextos y el mismo número de textos. Las métricas se recalcularon con las mismas funciones de evaluación y, en el caso semántico, con la misma revisión del codificador. Este análisis se decidió después de observar la ausencia de métricas, por lo que se presenta como exploratorio y no como sustituto del criterio original. Al excluir precisamente los contextos donde aparecieron salidas más degradadas, es probable que subestime el deterioro.

5.2. Perplejidad sobre referencias originales

La Tabla 1 resume la perplejidad de cada generación sobre las continuaciones humanas de prueba. Las generaciones iniciales obtuvieron valores entre 30.40 y 30.51. Con datos originales ($\alpha = 0$) la perplejidad se mantuvo prácticamente constante durante los cinco ciclos, con medias entre 30.40 y 30.49.

Ciclo	$\alpha = 0$	$\alpha = 0.5$	$\alpha = 1$
0 (M_0)		30.46 [30.40; 30.51]	
1	30.49 [30.46; 30.52]	31.61 [31.45; 31.76]	32.92 [32.81; 33.00]
2	30.46 [30.32; 30.57]	31.87 [31.57; 32.03]	34.46 [34.33; 34.73]
3	30.47 [30.43; 30.51]	31.86 [31.75; 32.06]	36.11 [35.74; 36.32]
4	30.40 [30.38; 30.42]	31.90 [31.85; 31.96]	38.03 [37.73; 38.53]
5	30.47 [30.40; 30.51]	31.90 [31.69; 32.18]	39.30 [39.01; 39.76]

Tabla 1: Perplejidad sobre referencias originales: media y rango [mínimo; máximo] de las tres cadenas por ciclo y proporción sintética α. M_0 es compartido por las tres proporciones dentro de cada repetición.

Con la mitad de objetivos sintéticos ($\alpha = 0.5$) la perplejidad aumentó en el primer ciclo hasta 31.61 y después se estabilizó cerca de 31.9. En el ciclo 5 la diferencia media frente a M_0 fue de +1.44, cerca de un 4.7 %. Con reemplazo total de los objetivos ($\alpha = 1$) la perplejidad creció en todos los ciclos: 32.92, 34.46, 36.11, 38.03 y 39.30. El aumento acumulado fue de +8.83, alrededor de un 29 % respecto de M_0, con incrementos por ciclo entre 1.3 y 2.5 y sin señal de estabilización dentro de los cinco ciclos observados. Las tres cadenas mostraron la misma dirección y los rangos de las tres condiciones dejaron de traslaparse desde el primer ciclo.

5.3. Diversidad léxica y repetición

La Figura 1 muestra las trayectorias del análisis complementario y la Tabla 2 resume las diferencias en el ciclo 5. Con $\alpha = 0$, Distinct-2 osciló entre 0.902 y 0.920, Distinct-3 entre 0.984 y 0.989 y la repetición media de 4-gramas entre 0.003 y 0.006, sin una tendencia definida.

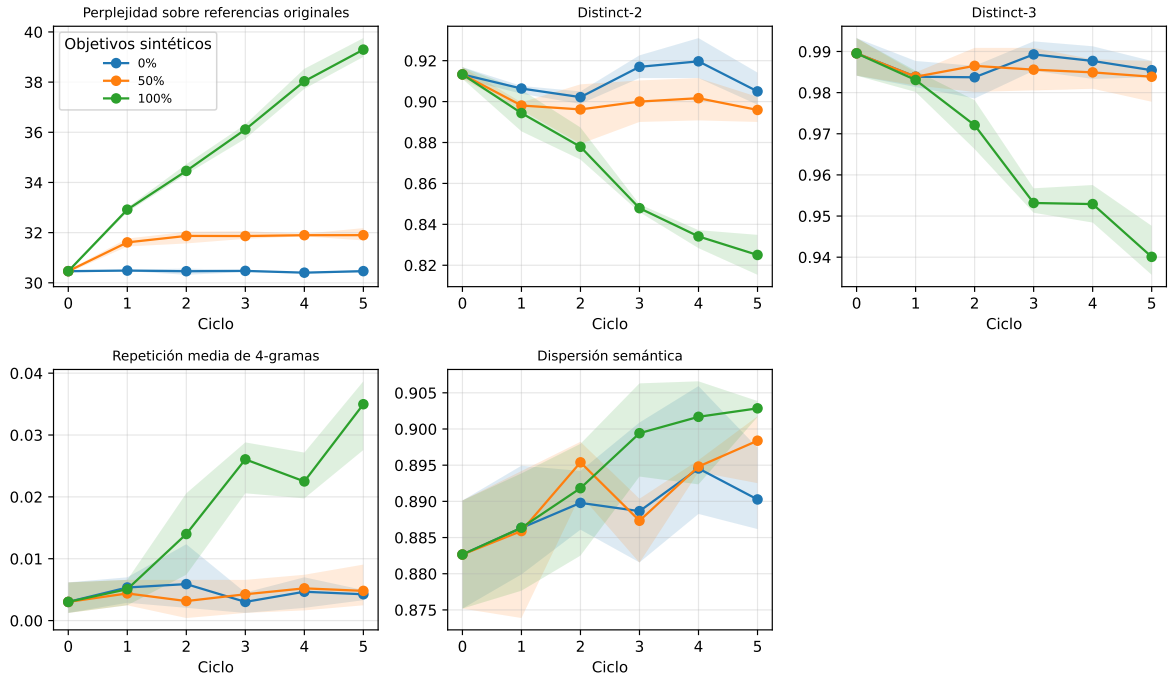


Figura 1: Trayectorias por ciclo y proporción sintética: media (línea) y rango de las tres cadenas (área sombreada). La perplejidad usa los 128 contextos de prueba; las demás métricas corresponden al análisis complementario *post hoc* con 90 contextos comunes y $W = 30$ palabras.

Con $\alpha = 1$, en cambio, la diversidad léxica disminuyó a partir del segundo ciclo. Distinct-2 pasó de 0.913 en M_0 a 0.825 en el ciclo 5, una reducción cercana al 10 %, y Distinct-3 pasó de 0.990 a 0.940. La repetición media de 4-gramas aumentó de 0.003 a 0.035. Aunque su valor absoluto sigue siendo bajo para fragmentos de 30 palabras, es alrededor de ocho veces mayor que el del control en el mismo ciclo. Las tres cadenas coincidieron en la dirección de estos cambios.

Con $\alpha = 0.5$ los cambios fueron pequeños y poco consistentes. Distinct-2 se mantuvo ligeramente por debajo del control, entre 0.896 y 0.902, pero en el ciclo 5 la diferencia frente al control fue -0.009, con un rango que incluye valores positivos. Distinct-3 y la repetición de 4-gramas no se distinguieron del control.

Métrica	α	Δ frente a M_0	Δ frente al control	Cadenas con $\Delta > 0$
Perplejidad	50 %	+1.44 [+1.21; +1.67]	+1.43 [+1.18; +1.70]	3/3
Perplejidad	100 %	+8.83 [+8.52; +9.36]	+8.83 [+8.50; +9.35]	3/3
Distinct-2	50 %	−0.0174 [−0.0268; −0.0088]	−0.0091 [−0.0241; +0.0038]	1/3
Distinct-2	100 %	−0.0883 [−0.0958; −0.0770]	−0.0799 [−0.0893; −0.0674]	0/3
Distinct-3	50 %	−0.0057 [−0.0155; +0.0036]	−0.0016 [−0.0099; +0.0028]	2/3
Distinct-3	100 %	−0.0495 [−0.0563; −0.0365]	−0.0454 [−0.0508; −0.0373]	0/3
Repetición de 4-gramas	50 %	+0.0018 [−0.0037; +0.0074]	+0.0005 [−0.0025; +0.0045]	1/3
Repetición de 4-gramas	100 %	+0.0320 [+0.0214; +0.0374]	+0.0307 [+0.0226; +0.0354]	3/3
Dispersión semántica	50 %	+0.0157 [+0.0024; +0.0257]	+0.0081 [+0.0035; +0.0145]	3/3
Dispersión semántica	100 %	+0.0202 [+0.0137; +0.0279]	+0.0126 [+0.0056; +0.0177]	3/3

Tabla 2: Diferencias descriptivas en el ciclo 5: media y rango de las tres cadenas. Δ frente a M_0 compara con el punto inicial de la misma repetición; Δ frente al control compara con la condición $\alpha = 0$ del mismo ciclo y repetición. No se calculan pruebas de significación. Salvo la perplejidad, calculada con los 128 contextos de prueba, las métricas corresponden al análisis complementario *post hoc* con los 90 contextos en los que todas las etapas alcanzan $W = 30$ palabras.

5.4. Dispersión semántica

La dispersión semántica no disminuyó en ninguna condición. Las medias aumentaron ligeramente en las tres proporciones: de 0.883 en M_0 a 0.890 con $\alpha = 0$, 0.898 con $\alpha = 0.5$ y 0.903 con $\alpha = 1$ en el ciclo 5. La diferencia frente al control con $\alpha = 1$ fue positiva en las tres cadenas, de +0.013 en promedio. Su magnitud es pequeña y los rangos se traslapan en varios ciclos, por lo que no se interpreta como un cambio robusto.

5.5. Interacción entre proporción sintética y generaciones

El efecto del número de ciclos dependió de la proporción sintética. Con $\alpha = 0$ las trayectorias fueron prácticamente planas. Con $\alpha = 0.5$ casi todo el cambio en perplejidad ocurrió en el primer ciclo y después se mantuvo estable, de modo que añadir generaciones no aumentó el efecto. Con $\alpha = 1$, en cambio, la perplejidad creció en promedio unas 1.8 unidades por ciclo y la diversidad léxica y la repetición empezaron a separarse del control a partir del segundo ciclo. Esta dependencia se describe a partir de las trayectorias; con tres repeticiones no se estimó un término de interacción formal.

5.6. Variabilidad entre repeticiones

Las tres cadenas de cada condición mostraron trayectorias muy parecidas. En el ciclo 5, el rango de la perplejidad fue de 0.10 con $\alpha = 0$, 0.49 con $\alpha = 0.5$ y 0.75 con $\alpha = 1$, muy inferior a las diferencias entre condiciones. En las métricas léxicas la variación entre cadenas fue mayor en proporción: el rango de Distinct-2 fue de 0.016 con $\alpha = 0$, 0.012 con $\alpha = 0.5$ y 0.020 con $\alpha = 1$. Esta variabilidad es del mismo orden que la diferencia entre $\alpha = 0.5$ y el

control, lo que explica que esa comparación no sea concluyente, pero es claramente menor que la diferencia observada con $\alpha = 1$.

5.7. Ejemplos de continuaciones

Los ejemplos siguientes provienen de la primera repetición y comparan, para un mismo contexto de prueba, la generación inicial con la generación del ciclo 5 bajo $\alpha = 1$. Se reproducen fragmentos iniciales sin corrección; las barras indican saltos de línea.

> M_0*:* «las hayas, tienden a caer en dos, que eran los procesos de formación de las flores. En el lado basal pueden haber algo de roseta media luna [. . .]»
>
> $\alpha = 1$*, ciclo 5:* «las estípulas, usan frutos, tallos y hojas en forma de flor (la inflorescencia es una flor de 16-30 cm de largo, ovoide, 21-25 cm de largo, 3.5 cm de ancho, 5 cm de largo, 2 cm de ancho, y 1.6 cm de largo, 1 cm de largo, 4 cm de largo, 6 cm de largo [. . .]»

> M_0*:* «La geología de la República de India es considerada el área más grande del mundo [. . .]»
>
> $\alpha = 1$*, ciclo 5:* «La espeleología incluye dos grandes áreas de estudio: / / / / Los países que tienen más aumento de población del mundo [. . .] son: / / / / En los países con más aumento de población del mundo [. . .] son: / / / / / / [. . .]»

Ambos textos de M_0 contienen errores de contenido, lo que es esperable en un modelo pequeño. Sin embargo, las continuaciones del ciclo 5 con $\alpha = 1$ muestran además bucles de una misma estructura, frases reiteradas y secuencias de saltos de línea. Estos patrones coinciden con el aumento de la repetición de 4-gramas y de las continuaciones cortas. Los ejemplos ilustran las mediciones y no sustituyen el análisis cuantitativo.

5.8. Aspectos previstos que no se evaluaron

Dos aspectos contemplados en la planeación no se midieron en esta ejecución. La representación de patrones poco frecuentes requería un procedimiento específico que no se implementó, y la repetición entre textos se aproximó únicamente mediante la dispersión semántica, sin una medida léxica de similitud entre continuaciones. Tampoco se aplicaron pruebas de significación; los contrastes se informan como diferencias descriptivas entre cadenas, de acuerdo con el análisis previsto.

6. Discusión

6.1. Lectura de los resultados frente a la hipótesis

La hipótesis planteaba que el entrenamiento recurrente con contenido sintético reduciría progresivamente la diversidad y aumentaría la repetición, con efectos más pronunciados al aumentar la proporción sintética y el número de generaciones. Los resultados la apoyan de forma parcial. Bajo reemplazo total de los objetivos ($\alpha = 1$) se observó el patrón esperado: menor diversidad léxica, mayor repetición y una perplejidad creciente sobre texto humano, acumulándose en cada ciclo. El orden entre condiciones también coincidió con lo esperado: el control se mantuvo estable, la mezcla intermedia mostró cambios moderados y el reemplazo total, los mayores.

La hipótesis no se cumplió en dos aspectos. Con $\alpha = 0.5$ el cambio no fue progresivo: la perplejidad aumentó en el primer ciclo y después se estabilizó, mientras que la diversidad léxica y la repetición apenas se separaron del control. Además, la dispersión semántica no disminuyó en ninguna condición. Por tanto, dentro de este diseño, el deterioro observado depende más del reemplazo completo de los datos originales que de la mera presencia de contenido sintético, y se manifiesta en la dimensión léxica y en la perplejidad antes que en la semántica medida.

6.2. Relación con la literatura

El comportamiento con $\alpha = 1$ es compatible con el deterioro descrito por Shumailov et al. [1]: cada generación aprende de una muestra del modelo anterior y asigna menor probabilidad al texto original. El aumento sostenido de la perplejidad sobre referencias humanas es la señal más directa de ese alejamiento. No obstante, el estudio no midió la pérdida de eventos poco frecuentes de forma específica y abarca solo cinco ciclos; por ello, los resultados se interpretan como una etapa temprana compatible con el fenómeno, no como un colapso avanzado.

La estabilización con $\alpha = 0.5$ coincide con los antecedentes que distinguen entre reemplazar los datos y conservar una parte de los originales [15, 2]. En este diseño la mitad de los objetivos humanos permanece fija en cada ciclo, lo que parece acotar el alejamiento respecto de la distribución original. Esta comparación es solo cualitativa: el experimento no evaluó la acumulación de generaciones ni corpus de tamaño creciente, que son las condiciones estudiadas en esos trabajos.

La diferencia entre dimensiones también es coherente con Guo et al. [9], quienes reportan reducciones más claras en la diversidad léxica y sintáctica que en la semántica. En este estudio, la dispersión semántica incluso aumentó ligeramente. Una explicación posible es

que la métrica compara continuaciones de 90 contextos con temas distintos, por lo que refleja sobre todo la variedad entre temas y no la concentración dentro de cada uno. Además, un texto que pierde coherencia con su contexto puede parecer más disperso para el codificador sin ser más variado. Ambas explicaciones son hipótesis y no se comprobaron en este trabajo.

Por último, la generación con *top-p* de 0.95 descarta en cada ciclo la parte menos probable de la distribución [5]. Como la configuración de muestreo fue constante, las diferencias entre condiciones no se deben a cambios en la decodificación. Sin embargo, este recorte podría contribuir a que los datos sintéticos pierdan variedad de una generación a otra, en línea con la influencia de la estrategia de generación señalada por Drayson et al. [8]. Comprobarlo requeriría comparar estrategias de muestreo.

6.3. Limitaciones

Los resultados se limitan a un GPT-2 pequeño en español, 512 ejemplos de Wikipedia, cinco ciclos y tres repeticiones. Con tres cadenas por condición el análisis es descriptivo: las diferencias se informan mediante medias y rangos, sin pruebas de significación. Que las tres cadenas coincidan en dirección y que los rangos no se traslapen respalda la consistencia de los cambios con $\alpha = 1$, pero no permite generalizar a otros modelos, tamaños o dominios.

La principal limitación metodológica es la pérdida de métricas léxicas y semánticas en 39 etapas por la regla de textos cortos. El análisis complementario permite describir esas dimensiones, pero se definió después de observar los datos y excluye 38 de los 128 contextos de prueba, probablemente los más afectados. Además, $W = 30$ palabras es una ventana breve; la dispersión semántica depende del codificador elegido; el modelo ya había sido adaptado a Wikipedia, por lo que no puede descartarse solapamiento con sus datos previos; y los contextos humanos se mantuvieron incluso con $\alpha = 1$. Cada ajuste partió del mismo modelo base, de modo que la transmisión entre generaciones ocurrió únicamente a través de los datos. Por último, no se evaluaron la diversidad sintáctica ni la pérdida de patrones raros con un procedimiento específico.

7. Conclusiones

7.1. Respuesta a la pregunta principal

Con un GPT-2 pequeño en español, la diversidad del contenido generado cambió de forma distinta según la proporción de datos sintéticos. Cuando las continuaciones originales se reemplazaron por completo, la diversidad léxica disminuyó de manera progresiva a lo largo de los cinco ciclos (Distinct-2 bajó cerca de un 10 % y Distinct-3 un 5 %). Al conservar la mitad

de los datos originales, los cambios fueron pequeños e inconsistentes, y con datos originales no se observaron cambios. La dispersión semántica, en cambio, no disminuyó en ninguna condición.

7.2. Respuestas a las preguntas secundarias

1. *Generaciones.* Con reemplazo total, la diversidad léxica disminuyó a partir del segundo ciclo y siguió bajando hasta el quinto. La dispersión semántica no se redujo; aumentó ligeramente en todas las condiciones.

2. *Proporción.* El efecto aumentó con la proporción sintética: nulo con $\alpha = 0$, moderado y estable con $\alpha = 0.5$ y el mayor con $\alpha = 1$. Conservar la mitad de los datos originales redujo considerablemente el deterioro.

3. *Repetición.* Con $\alpha = 1$ la repetición media de 4-gramas pasó de 0.003 a 0.035 y aparecieron bucles de una misma estructura, frases reiteradas y saltos de línea repetidos. Con $\alpha \leq 0.5$ la repetición no se distinguió del control.

4. *Relación entre ambos factores.* El número de generaciones amplificó el efecto solo bajo reemplazo total. Con la mezcla intermedia el cambio se concentró en el primer ciclo y después se estabilizó.

5. *Indicadores de model collapse.* Los rasgos que acompañaron el deterioro fueron el aumento sostenido de la perplejidad sobre texto humano, la caída de Distinct-n, el aumento de la repetición y la aparición de continuaciones degeneradas o muy cortas. La dispersión semántica no resultó un indicador útil en este diseño.

7.3. Cumplimiento de los objetivos

Se cumplieron los objetivos planteados dentro del alcance del experimento. Se compararon la diversidad léxica y semántica a través de cinco ciclos y tres proporciones, se evaluó la repetición dentro de los textos y se describió el efecto conjunto de ambos factores. La compatibilidad con el *model collapse* se examinó considerando sus limitaciones. El cumplimiento es descriptivo: las métricas léxicas y semánticas proceden de un análisis complementario y la repetición entre textos solo se aproximó mediante la dispersión semántica.

7.4. Conclusión sobre la hipótesis

La hipótesis se apoya parcialmente. Bajo reemplazo total de los datos originales se observaron la disminución progresiva de la diversidad léxica y el aumento de la repetición

que se esperaban, con efectos crecientes con las generaciones. No se apoya en la dimensión semántica medida ni en la mezcla intermedia, donde el efecto no fue progresivo. En conjunto, los resultados son compatibles con una etapa temprana de *model collapse* bajo reemplazo total, dentro de las condiciones evaluadas.

7.5. Aportaciones del estudio

El estudio aporta una comparación controlada en español de tres proporciones sintéticas y cinco generaciones, con tres repeticiones independientes, ejecutada en Google Colab con una GPU T4 y documentada con detalle suficiente para repetirla. Los resultados muestran también que conservar una fracción fija de datos originales limita el deterioro y que una regla de evaluación demasiado estricta puede dejar sin medición a la mayoría de las etapas, algo que conviene prever en estudios similares.

7.6. Limitaciones y trabajo futuro

Las conclusiones se limitan a un modelo pequeño, un corpus enciclopédico, cinco ciclos y tres repeticiones, y al análisis descriptivo. Como trabajo futuro se propone ampliar el número de ciclos y repeticiones, evaluar otros modelos, tareas e idiomas, comparar estrategias de muestreo y políticas de acumulación, incorporar medidas de diversidad sintáctica y de pérdida de patrones raros, y definir desde el inicio un tratamiento de las salidas cortas que no invalide etapas completas.

Referencias

[1] Shumailov, I., Shumaylov, Z., Zhao, Y., et al. *AI models collapse when trained on recursively generated data*. Nature, 631, 755–759, 2024. https://doi.org/10.1038/s41586-024-07566-y

[2] Kazdan, J., Schaeffer, R., Dey, A., Gerstgrasser, M., Rafailov, R., Donoho, D. L., y Koyejo, S. *Collapse or Thrive: Perils and Promises of Synthetic Data in a Self-Generating World*. Proceedings of the 42nd International Conference on Machine Learning, PMLR, 267, 29469–29494, 2025. https://proceedings.mlr.press/v267/kazdan25a.html

[3] Bengio, Y., Ducharme, R., Vincent, P., y Jauvin, C. *A Neural Probabilistic Language Model*. Journal of Machine Learning Research, 3, 1137–1155, 2003. https://jmlr.org/papers/v3/bengio03a.html

[4] Vaswani, A., Shazeer, N., Parmar, N., et al. *Attention Is All You Need*. Advances in Neural Information Processing Systems, 30, 2017. https://papers.nips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

[5] Holtzman, A., Buys, J., Du, L., Forbes, M., y Choi, Y. *The Curious Case of Neural Text Degeneration*. International Conference on Learning Representations, 2020. Preprint inicial: arXiv:1904.09751, 2019. https://arxiv.org/abs/1904.09751

[6] Wang, Y., Kordi, Y., Mishra, S., Liu, A., Smith, N. A., Khashabi, D., y Hajishirzi, H. *Self-Instruct: Aligning Language Models with Self-Generated Instructions*. Proceedings of ACL, 13484–13508, 2023. https://aclanthology.org/2023.acl-long.754/

[7] Zhu, X., Cheng, D., Li, H., et al. *How to Synthesize Text Data without Model Collapse?*. Proceedings of ICML, PMLR, 267, 79746–79771, 2025. https://proceedings.mlr.press/v267/zhu25d.html

[8] Drayson, G., Yilmaz, E., y Lampos, V. *Machine-generated text detection prevents language model collapse*. Proceedings of EMNLP, 29657–29673, 2025. https://aclanthology.org/2025.emnlp-main.1506/

[9] Guo, Y., Shang, G., Vazirgiannis, M., y Clavel, C. *The Curious Decline of Linguistic Diversity: Training Language Models on Synthetic Text*. Findings of NAACL, 3589–3604, 2024. https://aclanthology.org/2024.findings-naacl.228/

[10] Reimers, N., y Gurevych, I. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. Proceedings of EMNLP-IJCNLP, 3982–3992, 2019. https://aclanthology.org/D19-1410/

[11] Li, J., Galley, M., Brockett, C., Gao, J., y Dolan, B. *A Diversity-Promoting Objective Function for Neural Conversation Models*. Proceedings of NAACL-HLT, 110–119, 2016. https://aclanthology.org/N16-1014/

[12] Zhu, Y., Lu, S., Zheng, L., Guo, J., Zhang, W., Wang, J., y Yu, Y. *Texygen: A Benchmarking Platform for Text Generation Models*. Proceedings of SIGIR, 1097–1100, 2018. https://doi.org/10.1145/3209978.3210080

[13] Pillutla, K., Swayamdipta, S., Zellers, R., Thickstun, J., Welleck, S., Choi, Y., y Harchaoui, Z. *MAUVE: Measuring the Gap Between Neural Text and Human Text using Divergence Frontiers*. Advances in Neural Information Processing Systems, 34, 2021. https://papers.nips.cc/paper_files/paper/2021/hash/260c2432a0eecc28ce03c10dadc078a4-Abstract.html

[14] Suresh, A. T., Thangaraj, A., y Khandavally, A. N. K. *Rate of Model Collapse in Recursive Training*. Proceedings of the 28th International Conference on Artificial Intelligence and Statistics, PMLR, 258, 1396–1404, 2025. https://proceedings.mlr.press/v258/suresh25a.html

[15] Gerstgrasser, M., Schaeffer, R., Dey, A., et al. *Is Model Collapse Inevitable? Breaking the Curse of Recursion by Accumulating Real and Synthetic Data*. Preprint arXiv:2404.01413v2, 2024. https://doi.org/10.48550/arXiv.2404.01413

[16] Datificate. *Model card: gpt2-small-spanish*. Ficha del modelo consultada el 9 de noviembre de 2026. https://huggingface.co/datificate/gpt2-small-spanish

[17] Wikimedia. *Dataset card: Wikipedia*, configuración 20231101.es. Ficha del conjunto consultada el 9 de noviembre de 2026. https://huggingface.co/datasets/wikimedia/wikipedia

[18] Sentence Transformers. *Model card: paraphrase-multilingual-MiniLM-L12-v2*. Ficha del codificador consultada el 9 de noviembre de 2026. https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

A. Configuración completa del experimento

Parámetro	Valor
Modelo base	`datificate/gpt2-small-spanish` (rev. `02e30923`)
Corpus	`wikimedia/wikipedia`, `20231101.es` (rev. `b04c8d1c`)
Codificador semántico	`paraphrase-multilingual-MiniLM-L12-v2` (rev. `e8f8c211`)
Artículos recorridos	2000 (prefijo en streaming)
Semilla de partición y del estudio	20261109
Ejemplos de entrenamiento / validación / prueba	512 / 128 / 128
Tokens de contexto / objetivo	64 / 128
Proporciones sintéticas α	0, 0.5 y 1
Ciclos y repeticiones	5 ciclos, 3 repeticiones (48 ajustes)
Optimizador	AdamW, 2×10^{-5}, $\beta = (0.9, 0.999)$, $\epsilon = 10^{-8}$, decaimiento 0.01
Lote	efectivo 8 (microlotes de 2), 1 época, 64 actualizaciones
Recorte de gradiente	norma 1.0, float32, sin *scheduler*
Generación	temperatura 1.0, *top-p* 0.95, 128 tokens sin IDs especiales
Longitud léxica W	máximo 32; valor fijado con validación: 30
Límite del codificador	128 *wordpieces*
Entorno	Colab, Tesla T4, CUDA 13.0, Python 3.13.16, PyTorch 2.14.1, Transformers 5.22.2

Tabla 3: Configuración congelada en el protocolo del estudio principal.

Los contextos de entrada son los primeros 64 tokens de una ventana seleccionada al azar, con semilla fija, en cada artículo de Wikipedia; no se utilizaron instrucciones. Los identificadores de los artículos y las ventanas exactas se registraron para poder reconstruir el corpus.

B. Tablas completas de resultados

Las tablas siguientes presentan, por ciclo y proporción, las métricas del análisis complementario. La tabla de perplejidad se presentó en la sección de resultados.

Ciclo	$\alpha = 0$	$\alpha = 0.5$	$\alpha = 1$
0 (M_0)		0.9133 [0.9111; 0.9169]	
1	0.9064 [0.9038; 0.9077]	0.8981 [0.8958; 0.8996]	0.8944 [0.8854; 0.9057]
2	0.9022 [0.8989; 0.9050]	0.8962 [0.8793; 0.9084]	0.8779 [0.8716; 0.8874]
3	0.9170 [0.9115; 0.9226]	0.9000 [0.8900; 0.9103]	0.8479 [0.8460; 0.8498]
4	0.9197 [0.9115; 0.9310]	0.9017 [0.8908; 0.9115]	0.8341 [0.8284; 0.8372]
5	0.9050 [0.8985; 0.9142]	0.8959 [0.8900; 0.9023]	0.8250 [0.8153; 0.8349]

Tabla 4: Distinct-2: media y rango [mínimo; máximo] de las tres cadenas por ciclo y proporción sintética α. M_0 es compartido por las tres proporciones dentro de cada repetición. Salvo la perplejidad, calculada con los 128 contextos de prueba, las métricas corresponden al análisis complementario *post hoc* con los 90 contextos en los que todas las etapas alcanzan $W = 30$ palabras.

Ciclo	$\alpha = 0$	$\alpha = 0.5$	$\alpha = 1$
0 (M_0)		0.9896 [0.9841; 0.9933]	
1	0.9839 [0.9813; 0.9877]	0.9839 [0.9817; 0.9849]	0.9831 [0.9802; 0.9853]
2	0.9837 [0.9786; 0.9865]	0.9865 [0.9802; 0.9909]	0.9721 [0.9663; 0.9782]
3	0.9893 [0.9853; 0.9925]	0.9856 [0.9806; 0.9909]	0.9532 [0.9508; 0.9567]
4	0.9877 [0.9833; 0.9913]	0.9849 [0.9810; 0.9881]	0.9529 [0.9484; 0.9575]
5	0.9854 [0.9837; 0.9877]	0.9839 [0.9778; 0.9877]	0.9401 [0.9357; 0.9476]

Tabla 5: Distinct-3: media y rango [mínimo; máximo] de las tres cadenas por ciclo y proporción sintética α. M_0 es compartido por las tres proporciones dentro de cada repetición. Salvo la perplejidad, calculada con los 128 contextos de prueba, las métricas corresponden al análisis complementario *post hoc* con los 90 contextos en los que todas las etapas alcanzan $W = 30$ palabras.

Ciclo	$\alpha = 0$	$\alpha = 0.5$	$\alpha = 1$
0 (M_0)		0.0030 [0.0012; 0.0062]	
1	0.0053 [0.0029; 0.0070]	0.0044 [0.0025; 0.0066]	0.0051 [0.0025; 0.0066]
2	0.0059 [0.0021; 0.0123]	0.0032 [0.0004; 0.0066]	0.0140 [0.0074; 0.0206]
3	0.0030 [0.0012; 0.0045]	0.0043 [0.0012; 0.0066]	0.0261 [0.0206; 0.0288]
4	0.0047 [0.0021; 0.0070]	0.0052 [0.0016; 0.0074]	0.0225 [0.0198; 0.0272]
5	0.0043 [0.0033; 0.0049]	0.0048 [0.0025; 0.0091]	0.0350 [0.0276; 0.0387]

Tabla 6: Repetición media de 4-gramas: media y rango [mínimo; máximo] de las tres cadenas por ciclo y proporción sintética α. M_0 es compartido por las tres proporciones dentro de cada repetición. Salvo la perplejidad, calculada con los 128 contextos de prueba, las métricas corresponden al análisis complementario *post hoc* con los 90 contextos en los que todas las etapas alcanzan $W = 30$ palabras.

Ciclo	$\alpha = 0$	$\alpha = 0.5$	$\alpha = 1$
0 (M_0)		0.8827 [0.8752; 0.8901]	
1	0.8863 [0.8799; 0.8949]	0.8859 [0.8739; 0.8942]	0.8864 [0.8777; 0.8939]
2	0.8898 [0.8861; 0.8942]	0.8954 [0.8909; 0.8982]	0.8918 [0.8825; 0.8980]
3	0.8886 [0.8816; 0.9009]	0.8873 [0.8815; 0.8904]	0.8994 [0.8934; 0.9063]
4	0.8945 [0.8883; 0.9059]	0.8948 [0.8941; 0.8957]	0.9017 [0.8923; 0.9066]
5	0.8903 [0.8862; 0.8974]	0.8984 [0.8925; 0.9018]	0.9029 [0.9017; 0.9039]

Tabla 7: Dispersión semántica: media y rango [mínimo; máximo] de las tres cadenas por ciclo y proporción sintética α. M_0 es compartido por las tres proporciones dentro de cada repetición. Salvo la perplejidad, calculada con los 128 contextos de prueba, las métricas corresponden al análisis complementario *post hoc* con los 90 contextos en los que todas las etapas alcanzan $W = 30$ palabras.